NPU计算图划分与多核调度优化技术路线

面向三种存储场景的子图划分、核间分配与执行调度

计算图输入
算子依赖 • 计算周期 • 张量大小 • 存储位置

硬件与场景约束
核数 • L1/UB容量 • DDR带宽 • 同步开销

共同决策模型

子图如何划分 算子分配到哪一核 各核按何顺序执行

目标：最小化总完成时间 Makespan 约束：依赖、容量与执行资源

01 问题一：子图边界经DDR搬运的调度优化

场景A：子图作为任务执行，权衡并行计算收益与边界搬运开销

图结构分析
拓扑依赖
链与分支汇合
独立连通分量

基准候选：拓扑分块与最早完成分核

结构候选：链收缩与闭合小区域合并

场景A原始评估器
比较两个候选Makespan
保留耗时较小的方案

合并筛选兼顾搬运节约与并行性损失

复用图结构分析与候选生成方法

02 问题二：同核数据驻留下的分核与调度优化

场景B：同核数据可驻留L1/UB，跨核传输需要搬运与同步

活跃核预算
k = 1, ..., N
逐一生成候选
保留单核方案

候选一：独立连通分量成对交错执行

候选二：区域 / 交错 / 大分量拆分
通过核内调度与搬运代理代价筛选

补齐为目标N核方案
场景B原始评估器
跨核预算与候选择优

最终选择依据为实际N核Makespan，代理代价仅用于候选内部筛选

第二问入选方案作为第三问基准

03 问题三：共享L2 Cache场景下的候选调度优化

场景B + 共享L2：以原始FIFO Cache评估器计算耗时，保留基准候选

按拓扑深度分窗口
w = 4 / 10 / 16

窗口内连通分量分组
形成候选子图

前驱亲和分核
兼顾流水线负载

三个窗口候选
重新划分与分核

基准 + 三个窗口候选

按Cache Makespan择优
平局保留基准方案

同方案无L2 / 有L2配对评估
区分调度收益与Cache收益

窗口法包含子图划分与核分配变化；比较基准与新方案时，保持图、核数和配置一致

统一验证与结果分析

方案合法性
依赖顺序与容量约束

全量同口径对照
100图及题目要求核数

性能与成本
耗时、搬运、命中率

可追溯结果
方案、逐图指标与日志

问题一、二：单核参考与2 ~ 5核对照 问题三：1 ~ 5核无L2 / Cache配对
同时记录候选数量与求解时间，依据原始评估器口径解释额外搬运量

图 1 NPU计算图划分与多核调度优化总体技术路线